

从研究选题到可运行评测管线：2026-09-14 至 2026-09-18 工作记录

版本：公开脱敏版

记录周期：2026-09-14 00:00–2026-09-18 23:59 (UTC)

状态快照：2026-09-18 15:36 (UTC)

说明：本文按主任务归并历史聊天与本地交付物，不复述原始聊天，不包含凭据、邮箱、服务地址、完整机器路径、模型权重、训练日志或原始评测输出。

执行摘要

本周工作从“研究方向梳理”扩展到了“可以运行和审计的研究基础设施”。核心结果包括：

- 将世界模型与强化学习、On-Policy Distillation (OPD)、Token-level Credit Assignment 三条方向整理成一套 74 页研究方案，并导出对应 PDF。
- 将电脑操作 Agent 的成功/失败轨迹问题收敛为 BranchCUA：强调同状态下的反事实分支、失败定位与恢复能力，形成 28 页技术材料。
- 完成 2025–2026 年大模型隐空间研究梳理：81 条论文记录、重点论文集合、24 页综述、选题建议以及本地代码环境。
- 实现面向大模型服务的 GPU/worker 守护与二次确认告警；完成一次异常重启的只读诊断。
- 重构 QA 评测器，接入检索、多轮回答、严格判分、断点恢复和运行遥测，并启动 7 个数据集、51,713 个样本的全量 Pass@1 评测。
- 审计本地检索系统：约 10.9M 条 passage、768 维 E5 向量、精确内积索引、Top-7 检索，无重排器。
- 对 5 组实验、6 个数据集重新计算 Avg@3、Rate 和 Calls/Used，形成 30 行可审计汇总。
- Coconut 的环境、模型、数据和运行脚本已准备并通过阶段性冒烟测试，但三模型完整训练尚未完成。

总体上，本周形成了六类可以继续复用的资产：研究方案、数据集方案、文献地图、实验环境、评测工具和运行监控。当前最需要收尾的是全量 QA 评测和 Coconut 正式训练。

当前状态总览

工作项	状态	可核查结果
三条研究路线汇报	已完成	74 页 PPT；对应 PDF 74 页
BranchCUA 数据集方案	已完成	28 页 PPT；存在 QA 记录
异常重启诊断	已完成诊断	确认属于非正常结束；最终物理根因仍需管理控制器日志
GPU/大模型服务监控	已部署	定时检测、二次确认、单事故单告警
隐空间论文与选题调研	已完成首版	81 条记录；24 页综述；论文索引与研究地图
Coconut 本地实验	部分完成	环境和脚本完成；GPT-2 有 6 个阶段检查点；完整三模型训练未完成
QA 评测器	工具完成	约 6.3k 行源码与测试；pilot 覆盖 7 个数据集
QA 全量评测	运行中	快照时完成 20,260 / 51,713，约 39.2%
检索系统审计	已完成	约 10.9M 条语料、768 维精确索引、Top-7
历史指标汇总	已完成	5 组实验 × 6 个数据集，共 30 行结果

1. 三条研究路线：从宽泛方向变成可讨论的问题定义

我做了什么

我提出了三条希望继续推进的研究方向，并要求整理成能够向导师完整说明动机、研究问题、实验设计和风险的汇报材料：

- 1. 世界模型与强化学习结合；
- 2. 纯 On-Policy Distillation；
- 3. Token-level 非对称信用分配。

在讨论过程中，我确认采用完整的 74 页结构，并要求材料不仅介绍论文，还要落到可验证的问题和实验方案。

模型给出了什么

模型把三个方向进一步收敛为：

- **世界模型方向**：重点不只是预测未来，而是评估决策风险、校准不确定性，并研究模型预测对策略更新的实际价值。
- **OPD 方向**：研究哪些学生状态可被教师有效指导、教师信息预算如何分配，以及学生超越教师时如何避免蒸馏成为上限。
- **Token Credit 方向**：用反事实 chunk/token 贡献替代单一序列级奖励，为关键推理步骤提供更细粒度信用。

模型随后生成研究 PPT、PDF、设计说明与实施计划，并对页面数量和导出结果进行检查。

形成的成果

- 研究方案演示稿：74 页。
- 完整 PDF：74 页。
- 设计说明与实施计划。
- OPD 部分被进一步整理为可单独阅读的研究内容，包含 TG-EOPD、BPT-OPD 和 token credit 等构想。

公开版文件标识

- `<RESEARCH_OUTPUT>/research_routes_2026-09-14.pptx`
- `<RESEARCH_OUTPUT>/research_routes_2026-09-14.pdf`
- `<DESIGN_DOCS>/research_routes_presentation_design.md`
- `<DESIGN_DOCS>/research_routes_presentation_plan.md`

这些原始文件仍位于本地研究工作区，本仓库只记录成果和状态，不直接分发内部演示稿。

2. BranchCUA：把“失败轨迹数据”改造成反事实恢复问题

我做了什么

我询问：收集电脑操作 Agent 的正确轨迹和错误轨迹是否具有研究价值，并要求形成一份单独的研究汇报。

模型给出了什么

模型认为，仅给整条轨迹标记“成功/失败”研究价值有限，更有价值的是构造同一环境状态下的可执行分支：

- 当前动作继续成功；
- 当前动作导致失败；
- 失败后可以恢复；
- 失败后进入不可恢复状态；
- 哪一个动作是关键分叉点；
- 什么恢复动作能够回到可完成区域。

据此提出 BranchCUA 数据集构想。数据集的主要价值不是分类，而是支持失败定位、动作信用分配、恢复策略学习和反事实评估。

形成的成果

- 28 页 BranchCUA 技术介绍 PPT。
- 数据集设计说明、实施计划和演示稿生成源文件。
- QA 记录，用于检查文件结构和导出结果。

公开版文件标识

- `<RESEARCH_OUTPUT>/branchcua_counterfactual_recovery_2026-09-14.pptx`

- `<BRANCHCUA_SOURCE>/`
- `<DESIGN_DOCS>/branchcua_dataset_design.md`
- `<DESIGN_DOCS>/branchcua_dataset_plan.md`

3. 异常重启诊断与 GPU/服务监控

我做了什么

我要求在不删除、不修改业务数据的前提下调查服务器为什么重启。随后又要求建立定时监控：检查 GPU 和大模型 worker，只有在 worker 消失、GPU 同时空闲并经过再次确认后才发送邮件，而且同一事故只发送一次。

模型给出了什么

只读日志分析确认：

- 上一轮运行并非正常关机；
- 系统日志出现中断，新启动时出现文件系统恢复迹象；
- 可以将问题归为断电、硬复位、系统完全失去响应或未记录的内核/硬件故障；
- 仅凭操作系统日志不能继续区分具体物理原因，最终确认仍需要服务器管理控制器的事件日志。

监控实现采用保守判断：

1. worker 不存在；
2. 相关 GPU 的显存和利用率同时较低；
3. 等待一个确认窗口后再次检测；
4. 第二次仍异常才告警；
5. 同一事故只发送一封通知。

形成的成果

- GPU/worker 监控程序、核心判断逻辑和测试。
- systemd service/timer 部署方式。
- 监控状态文件和单事故去重机制。
- 核心、测试及扩展监控代码合计约 2.9k 行。

公开版文件标识

- `<MONITOR_SOURCE>/vllm_gpu_watch/`
- `<MONITOR_SOURCE>/vllm_gpu_watch/app.py`
- `<MONITOR_SOURCE>/vllm_gpu_watch/core.py`
- `<DESIGN_DOCS>/vllm_gpu_watch_design.md`
- `<DESIGN_DOCS>/vllm_gpu_watch_plan.md`

公开版本不包含部署配置、收件地址、机器账号、服务端点或系统目录。

4. 大模型隐空间研究地图与实验环境

我做了什么

我要求系统调研 2025–2026 年 arXiv 上与隐空间推理、连续思维和 latent reasoning 相关的工作，优先关注大型研究机构和顶尖高校；同时要求下载重点论文、总结选题、收集代码项目，并检查常用训练框架的适配情况。

模型给出了什么

模型完成了：

- 81 条论文记录，其中包含 77 个 arXiv 标识；
- 重点论文集合；
- 24 页中文详细综述；
- 442 行可编辑研究地图；
- 论文索引和建议阅读顺序；
- 经典隐空间项目与较新的 latent-RL 项目集合；
- 公共 Python/Conda 环境与依赖文件。

研究建议主要收敛为两类：

- **CaL-Audit**：审计连续隐状态是否真的承载了可验证推理信息；
- **CALM-RL**：把隐空间推理、可控计算预算和强化学习结合起来。

环境准备过程中还确认了实际显存条件与初始假设不一致，因此后续实验规模需要按真实硬件预算调整。

公开版文件标识

- `<LATENT_RESEARCH>/latent_space_review_2025_2026.pdf`
- `<LATENT_RESEARCH>/latent_space_research_map.md`
- `<LATENT_RESEARCH>/paper_index.csv`
- `<LATENT_RESEARCH>/recommended_reading/README.md`
- `<ENV_ROOT>/latent-common/`
- `<ENV_ROOT>/latent-common-requirements.txt`

第三方论文 PDF 和第三方仓库不会随本周报告重新分发；公开版本仅记录索引和来源信息。

5. OPD 重点论文整理

我做了什么

我要求把 6 篇与 On-Policy Distillation 直接相关的论文下载到研究材料目录，便于继续阅读和形成后续实验设计。

模型给出了什么

已整理的主题包括：

- OPD 的不同形式和统一视角；
- 学生超越教师；
- 加速 OPD；
- 剪枝与预算分配；
- f-divergence 视角；
- 统一 OPD 框架。

形成的成果

6 篇论文已在本地研究材料区归档，并被用于 74 页研究方案中 OPD 部分的分析。公开仓库不复制这些第三方 PDF，只保留主题说明。

6. Coconut：本地环境和阶段性训练验证

我做了什么

我要求解释并配置 Coconut，准备 GPT-2、Llama-3B 级模型和 Qwen-3B 级模型，准备 ProsQA、GSM8K、ProntoQA 等数据，并在指定 GPU 上完成冒烟测试，随后启动三模型完整训练。

模型给出了什么

模型完成了：

- Coconut 项目、本地运行手册与脚本整理；
- 三类模型和多类推理数据的本地准备；
- 两个较大模型的前向冒烟测试；
- 其中一个模型的反向传播与参数更新测试；
- 三模型顺序训练脚本、日志目录和输出目录设计。

当前真实状态

- 本地环境和脚本已准备；
- GPT-2 路线产生了 6 个阶段检查点；
- 另外两条完整训练路线尚未形成检查点；
- 三模型完整训练目前不能视为完成；
- 后续随机种子复现实验尚未执行。

公开版文件标识

- `<EXPERIMENT_ROOT>/coconut/`
- `<EXPERIMENT_ROOT>/coconut/LOCAL_RUNBOOK.md`
- `<EXPERIMENT_ROOT>/coconut/scripts/local/`

- `<EXPERIMENT_ROOT>/coconut/data/`

模型权重、检查点、日志、PID/lock 文件和机器配置不进入公开仓库。

7. QA 评测器重构与七数据集全量评测

我做了什么

我要求检查旧评测代码和历史 `evaluation_*.json`，解释原有判分方式，然后重新实现一个干净的评测器，不直接复制旧文件。随后给出模型服务和检索服务，指定 Top-7 检索、较长生成上限、7 个数据集、Pass@1、并发 28，并要求保存输出、支持暂停和恢复。

模型给出了什么

旧实现中发现两个重要问题：

- Judge 对 `YES` 的匹配过于严格，容易产生格式型误判；
- 配置中存在不应硬编码的凭据字段。

新评测器提供：

- 标准化 exact match；
- exact match 不通过时调用结构化 LLM Judge；
- 检索调用和多轮回答；
- 数据集级与样本级进度记录；
- 断点恢复、运行状态、错误分类和磁盘保护；
- 单样本验证与七数据集 pilot；
- 全量运行器。

评测器源码和测试约 6.3k 行。

状态快照

截至 2026-09-18 15:36 UTC，状态文件记录：

- 计划样本：51,713；
- 已完成：20,260，约 39.2%；
- 正确：10,608；
- 错误：9,537；
- 模型失败：109；
- 未解析：6。

当前完成样本中的阶段性正确率约为 52.4%，但这不是最终结果。Judge 与被测模型来自同一模型服务，因此判分独立性有限，最终结论需要独立 Judge 或抽样人工复核。

公开版文件标识

- `<QA_EVALUATOR>/README.md`
- `<QA_EVALUATOR>/evaluate.py`
- `<QA_EVALUATOR>/run_full.py`
- `<QA_RUN>/run_status.json`
- `<QA_RUN>/run_report.md`

原始模型输出、运行配置、端点、凭据字段和样本级结果不进入公开仓库。

8. 检索系统审计：明确论文里究竟应该怎么写

我做了什么

我要求从启动脚本向下追踪检索服务、编码模型、语料文件、索引构建过程和实际返回条数，并整理成论文中可以使用的准确描述。

模型给出了什么

审计确认：

- 语料规模：10,925,232 条有效 passage；
- 稠密编码器：E5-base-v2；
- 向量维度：768；
- 池化与归一化：mean pooling + L2 normalization；
- 索引类型：FAISS `IndexFlatIP`；
- 检索方式：精确内积搜索；
- query 最大长度：256；
- 每次返回 Top-7；
- 当前没有 reranker。

这项工作消除了“启动参数、源代码默认值和论文描述是否一致”的不确定性，并生成了独立审计报告和语料统计文件。

公开版文件标识

- `<RETRIEVAL_AUDIT>/retrieval_setup_audit.md`
- `<RETRIEVAL_AUDIT>/retrieval_corpus_audit.json`

原始审计文件包含本机路径和服务信息，因此本仓库只保留经过脱敏的结论摘要。

9. 历史评测结果重新汇总

我做了什么

我提供了 5 组历史实验结果目录，要求统一计算 Avg@3、Rate、Calls/Used，并确保失败或未评分样本不会被悄悄排除出分母。

模型给出了什么

模型重新解析 5 组实验、6 个数据集，共形成 30 行数据集级结果，并保存：

- 数据集级汇总；
- pooled 汇总；
- 中文汇总表；
- 计算脚本；
- 每组实验的审计 JSON；
- 总体审计记录。

计算时保留失败和未评分运行。模型同时指出：失败轨迹中的工具调用可能没有被日志完整记录，因此 Calls/Used 应理解为“日志中实际记录到的调用”，不能直接等同于真实调用总数。

公开版文件标识

- `<METRICS_OUTPUT>/summary.csv`
- `<METRICS_OUTPUT>/metrics_by_dataset.csv`
- `<METRICS_OUTPUT>/metrics_pooled.csv`
- `<METRICS_OUTPUT>/calculate_metrics.py`
- `<METRICS_OUTPUT>/metrics_audit.json`

工程与版本管理状态

本周产出并不都已经进入主分支：

- 研究路线演示稿所在工作区已保持干净，但大型产物属于本地构建成果。
- GPU 监控主体已经形成独立功能分支；可选的评测进程监控仍是未跟踪扩展。
- QA 评测器主体已有分支和基础提交，但后续检索接入与全量运行相关改动仍需要整理提交。
- Coconut 包含实验脚本、输出和本地改动，不应被描述为可直接发布的干净软件版本。
- 当前主仓库主要跟踪设计/计划文档；大量实验产物位于忽略或未跟踪目录。

因此，“文件存在”和“代码已经合并、可复现发布”是两个不同状态。后续应先整理最小可复现代码，再选择性公开。

本周形成的关键判断

1. 研究选题需要从方法名称转向可证伪问题。世界模型、OPD 和 Token Credit 都被重新表述为可以设计对照实验的问题。
2. 失败数据的价值在分支结构，而不只是失败标签。BranchCUA 的核心是同状态反事实和恢复可达性。
3. 评测工具必须把运行证据作为一等公民。断点、状态、错误类型、Judge 配置和分母定义都必须可追溯。
4. 同模型 Judge 只能作为阶段性工具。它适合快速推进，但不足以支撑最终可信结论。
5. 本地实验产物需要区分“完成、运行中、准备完成”。本周最明显的例子是 QA 全量评测与 Coconut 完整训练。
6. 公开交付前必须做环境脱敏。运行目录、配置、日志和模型权重不应直接进入公开仓库。

下一步建议

按依赖关系，建议先完成以下三件事：

1. 让 QA 全量评测完成或从有效断点恢复，冻结最终结果并使用独立 Judge 复核代表性样本。
2. 清理 QA 评测器分支，将运行配置改为模板或环境变量，并提交最小可复现版本。
3. 重新设计 Coconut 完整训练的资源分配与恢复策略，先完成单模型端到端闭环，再扩展到三模型和多随机种子。

脱敏与证据说明

本报告依据本周主会话、工作区文件、运行状态文件和生成物元数据整理。为适合公开 GitHub 仓库，已执行以下处理：

- 删除密码、Token、邮箱和其他凭据；
- 删除服务 IP、端口、进程号和机器账号；
- 将绝对路径替换为逻辑路径标识；
- 不上传原始聊天、样本级模型输出、运行日志、配置快照或模型权重；
- 不重新分发第三方论文 PDF；
- 将仍在运行的指标明确标记为阶段性快照；
- 将未完成训练明确标记为未完成。

逻辑路径和本地真实路径的映射保存在私有附录中，不随公开仓库发布。